HURTOWNIE DANYCH

Laboratorium 2

Maciej Kopiński 254578

Zad. 1. Ekstrakcja danych

1. Utworzyć tabelę Sprzedaz zawierającą dane dotyczące liczby sprzedanych produktów przez pracowników firmy AdventureWorks w poszczególnych latach zgodnie z podanym schematem:

Sprzedaz (pracID, prodID, "Nazwa produktu", Rok, Liczba).

Wykonać to samo zapytanie przy użyciu polecenia pivot:

- a. w kolejnych kolumnach wyświetlić lata;
- b. w kolejnych kolumnach wyświetlić 5 najlepszych produktów.
- 2. Utworzyć zestawienie, które dla poszczególnych miesięcy i lat przedstawi informację o liczbie różnych klientów. Przygotuj zapytanie z i bez użycia polecenia pivot.
- 3. Utworzyć zestawienie zawierające w wierszach imiona i nazwiska sprzedawców, a w kolumnach kolejne lata. Wartością będzie liczba obsłużonych transakcji.

Wyświetlić tylko tych sprzedawców, którzy pracowali przez wszystkie 4 lata.

- 4. Zdefiniować zapytanie wyznaczające sumę kwot sprzedaży towarów oraz liczbę różnych produktów w zamówieniach w poszczególnych latach, miesiacach, dniach.
- 5. Wykorzystując polecenie CASE przygotować podsumowania do zestawienia z poprzedniego zadania tak, aby sumowane były kwoty zamówień oraz obliczana liczba różnych produktów dla poszczególnych miesięcy i dni tygodnia.
- 6. Przygotować zestawienie, w którym dla wybranych klientów przygotujemy kartę lojalnościową:
 - a. srebrną, jeśli klient wykonał co najmniej 5 transakcji w sklepie;
 - złotą, jeśli klient wykonał co najmniej 2 transakcje, której kwota przekraczała 150% średniej wartości zamówień w bazie (łączna kwota przekraczała 300% i każda z transakcji przekraczała 150%);
- c. platynową, jeśli klient co roku spełniał warunki otrzymania karty złotej. Schemat wynikowej tabeli powinien wyglądać następująco:

KartyLojalnosciowe(Imie, Nazwisko, Liczba transakcji, Łączna kwota transakcji, Kolor karty)

Zad. 2. Analiza danych

- 1. Przedstaw wyniki zadania 1 w postaci tabel i wykresów przestawnych w programie MS Excel. Zinterpretuj wyniki.
- 2. Przygotuj 5 dodatkowych tabel/wykresów, które pokażą ciekawe zależności w bazie AdventureWorks przy użyciu narzędzia Power BI lub Tableau.

Zad. 3. Ocena jakości danych – profilowanie danych

- 1. Przeanalizować, scharakteryzować i ocenić dane znajdujące się w plikach dane_1.txt oraz dane_2.csv wykorzystując profilowanie danych pakietu Visual Studio: projekt *Integration Services Project*. Z menu bocznego *SSIS Toolbox* należy:
 - a. wybrać bloczek Data Profiling Task (przeciągnąć na kanwę projektu),
 - b. określić dane w sekcji Destination,
 - c. skonfigurować Quick Profile,
 - d. uruchomić pakiet (Run).
- 2. Aby obejrzeć wynik należy użyć *Data Profile Viewer* lub ponownie edytując bloczek *Data Profiling Task* użyć opcji *Open Profile Viewer*.

Rozwiązania i wnioski:

Ad.1

```
1)
WITH Sprzedaz AS
       SELECT Sales.SalesPerson.BusinessEntityID, Sales.SalesOrderDetail.ProductID,
Production.Product.Name, YEAR(Sales.SalesOrderHeader.OrderDate) AS Rok,
SUM(Sales.SalesOrderDetail.OrderQty) AS Liczba
       FROM Sales Sales Person
       RIGHT JOIN Sales.SalesOrderHeader ON Sales.SalesOrderHeader.SalesPersonID =
Sales.SalesPerson.BusinessEntityID
       JOIN Sales.SalesOrderDetail ON Sales.SalesOrderDetail.SalesOrderID =
Sales.SalesOrderHeader.SalesOrderID
      JOIN Production.Product ON Production.Product.ProductID =
Sales.SalesOrderDetail.ProductID
      GROUP BY Sales.SalesPerson.BusinessEntityID, Sales.SalesOrderDetail.ProductID,
Production.Product.Name, YEAR(Sales.SalesOrderHeader.OrderDate)
SELECT *
FROM Sprzedaz;
```

```
1.a)
SELECT PracownikID, ProduktID, "Nazwa produktu", [2011], [2012], [2013], [2014]
SELECT sp.BusinessEntityID AS PracownikID, sod.ProductID AS ProduktID,
Production.Product.Name AS "Nazwa produktu", YEAR(soh.OrderDate) AS Rok, sod.OrderQty
AS "Liczba produktów"
FROM Sales.SalesPerson sp
RIGHT JOIN Sales.SalesOrderHeader soh ON soh.SalesPersonID = sp.BusinessEntityID
JOIN Sales.SalesOrderDetail sod ON sod.SalesOrderID = soh.SalesOrderID
JOIN Production.Product ON Production.ProductID = sod.ProductID
) AS sumamry
PIVOT(
SUM("Liczba produktów")
FOR Rok IN ([2011], [2012], [2013], [2014])
) AS P
ORDER BY 1;
1.b)
SELECT pracID, Rok, [712], [870], [711], [715], [708]
FROM(
      SELECT ssp.BusinessEntityID AS pracID, pp.ProductID AS prodID,
             YEAR(ssoh.OrderDate) AS Rok, ssod.OrderQty AS Liczba
       FROM Sales Sales Person ssp
       RIGHT JOIN Sales.SalesOrderHeader ssoh ON ssp.BusinessEntityID =
ssoh.SalesPersonID
       JOIN Sales.SalesOrderDetail ssod ON ssod.SalesOrderID = ssoh.SalesOrderID
       JOIN Production.Product pp ON pp.ProductID = ssod.ProductID
      WHERE pp.ProductID IN (SELECT TOP 5 ProductID FROM Sales.SalesOrderDetail GROUP
BY ProductID ORDER BY SUM(OrderQty) DESC)
) x
PIVOT(
      SUM(Liczba)
FOR
      prodID in ([712], [870], [711], [715], [708])
ORDER BY 1, 2;
2)
SELECT Rok, [1], [2], [3], [4], [5], [6], [7], [8], [9], [10], [11], [12]
SELECT DISTINCT YEAR(s.OrderDate) AS Rok, MONTH(s.OrderDate) AS Miesiac, s.CustomerId
AS "Roczni klienci"
FROM Sales.SalesOrderHeader s) AS summary
COUNT("Roczni klienci")
FOR Miesiac IN ([1], [2], [3], [4], [5], [6], [7], [8], [9], [10], [11], [12])) AS P
ORDER BY 1;
```

```
3)
SELECT "Imie i nazwisko", [2011], [2012], [2013], [2014]
SELECT p.FirstName + ' ' + p.LastName AS "Imie i nazwisko",
YEAR(Sales.SalesOrderHeader.OrderDate) AS Rok, Sales.SalesOrderHeader.SalesOrderID AS
"Liczba transakcji"
FROM Person Person p
JOIN Sales.SalesPerson ON Sales.SalesPerson.BusinessEntityID = p.BusinessEntityID
JOIN Sales.SalesOrderHeader ON Sales.SalesOrderHeader.SalesPersonID =
Sales.SalesPerson.BusinessEntityID) AS summary
COUNT("Liczba transakcji")
FOR Rok IN ([2011], [2012], [2013], [2014])) AS P;
4)
SELECT YEAR(Sales.SalesOrderHeader.OrderDate) AS Rok,
MONTH(Sales.SalesOrderHeader.OrderDate) AS Miesiąc,
DAY(Sales.SalesOrderHeader.OrderDate) AS Dzień,
SUM(Sales.SalesOrderHeader.TotalDue) AS Suma, COUNT(DISTINCT
Sales.SalesOrderDetail.ProductID) AS "Liczba różnych produktów"
FROM Sales.SalesOrderHeader
JOIN Sales.SalesOrderDetail ON Sales.SalesOrderDetail.SalesOrderID =
Sales.SalesOrderHeader.SalesOrderID
GROUP BY YEAR(Sales.SalesOrderHeader.OrderDate),
MONTH(Sales.SalesOrderHeader.OrderDate), DAY(Sales.SalesOrderHeader.OrderDate)
ORDER BY 1, 2, 3;
```

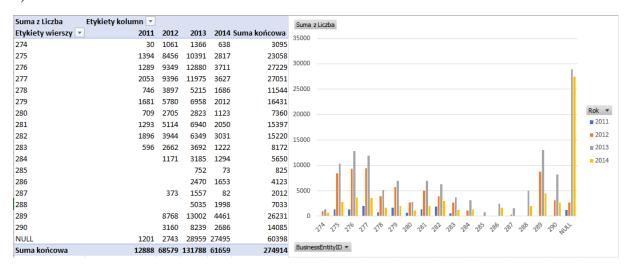
```
SELECT CASE
      WHEN MONTH(Sales.SalesOrderHeader.OrderDate) = 1 THEN 'Styczeń'
      WHEN MONTH(Sales.SalesOrderHeader.OrderDate) = 2 THEN 'Luty'
      WHEN MONTH(Sales.SalesOrderHeader.OrderDate) = 3 THEN 'Marzec'
      WHEN MONTH(Sales.SalesOrderHeader.OrderDate) = 4 THEN 'Kwiecień'
      WHEN MONTH(Sales.SalesOrderHeader.OrderDate) = 5 THEN 'Maj'
      WHEN MONTH(Sales.SalesOrderHeader.OrderDate) = 6 THEN 'Czerwiec'
      WHEN MONTH(Sales.SalesOrderHeader.OrderDate) = 7 THEN 'Lipiec'
      WHEN MONTH(Sales.SalesOrderHeader.OrderDate) = 8 THEN 'Sierpień'
      WHEN MONTH(Sales.SalesOrderHeader.OrderDate) = 9 THEN 'Wrzesień'
      WHEN MONTH(Sales.SalesOrderHeader.OrderDate) = 10 THEN 'Październik'
      WHEN MONTH(Sales.SalesOrderHeader.OrderDate) = 11 THEN 'Listopad'
      WHEN MONTH(Sales.SalesOrderHeader.OrderDate) = 12 THEN 'Grudzień'
      ELSE NULL
END Miesiąc,
CASE
      WHEN DATEPART(dw, Sales.SalesOrderHeader.OrderDate) = 1 THEN 'Poniedziałek'
      WHEN DATEPART(dw, Sales.SalesOrderHeader.OrderDate) = 2 THEN 'Wtorek'
      WHEN DATEPART(dw, Sales.SalesOrderHeader.OrderDate) = 3 THEN 'Sroda'
      WHEN DATEPART(dw, Sales.SalesOrderHeader.OrderDate) = 4 THEN 'Czwartek'
      WHEN DATEPART(dw, Sales.SalesOrderHeader.OrderDate) = 5 THEN 'Piqtek'
      WHEN DATEPART(dw, Sales.SalesOrderHeader.OrderDate) = 6 THEN 'Sobota'
      WHEN DATEPART(dw, Sales.SalesOrderHeader.OrderDate) = 7 THEN 'Niedziela'
      ELSE NULL
END Dzień,
SUM(Sales.SalesOrderHeader.TotalDue) AS Suma, COUNT(DISTINCT
Sales.SalesOrderDetail.ProductID) AS "Liczba różnych produktów"
FROM Sales.SalesOrderHeader
JOIN Sales.SalesOrderDetail ON Sales.SalesOrderDetail.SalesOrderID =
Sales.SalesOrderHeader.SalesOrderID
GROUP BY MONTH(Sales.SalesOrderHeader.OrderDate), DATEPART(dw,
Sales.SalesOrderHeader.OrderDate) ORDER BY MONTH(Sales.SalesOrderHeader.OrderDate),
DATEPART(dw, Sales.SalesOrderHeader.OrderDate);
```

```
6)
```

```
SELECT COUNT(*) FROM (
SELECT p.FirstName, p.Lastname, COUNT(ssoh.SalesOrderID) AS "Liczba transakcji",
SUM(ssoh.TotalDue) AS "Łączna kowata transakcji",
WHEN (SELECT COUNT(soh.TotalDue)
FROM Sales.Customer c
JOIN Sales.SalesOrderHeader soh ON soh.CustomerID = c.CustomerID
WHERE soh.TotalDue > 1.5*(SELECT AVG(soh.TotalDue) FROM Sales.SalesOrderHeader soh)
AND soh.CustomerID = cus.CustomerID) >= 2 THEN (
CASE
WHEN (SELECT COUNT(DISTINCT Y)
FROM (
SELECT CustomerID, YEAR(sohh.OrderDate) Y, COUNT(sohh.TotalDue) C
FROM Sales.SalesOrderHeader sohh
WHERE sohh.TotalDue > 1.5*(SELECT AVG(soh.TotalDue) FROM Sales.SalesOrderHeader soh)
GROUP BY CustomerID, YEAR(sohh.OrderDate)
HAVING COUNT(sohh.TotalDue) >= 2
) B ) >= (SELECT COUNT(DISTINCT soh.OrderDate) FROM Sales.SalesOrderHeader soh WHERE
soh.CustomerID = cus.CustomerID) THEN 'Platynowa'
ELSE 'Złota'
END
WHEN COUNT(ssoh.SalesOrderID) >= 5 THEN 'Srebrna'
END Karta
FROM Person Person P
JOIN Sales.Customer cus ON cus.PersonID = p.BusinessEntityID
JOIN Sales.SalesOrderHeader ssoh ON ssoh.CustomerID = cus.CustomerID
GROUP BY p.FirstName, p.LastName, cus.CustomerID, YEAR(ssoh.OrderDate)) A
WHERE A.Karta = 'Platynowa';
```

Ad.2 – Wnioski do wykresów powstałych z wyników kwerend z zadania 1

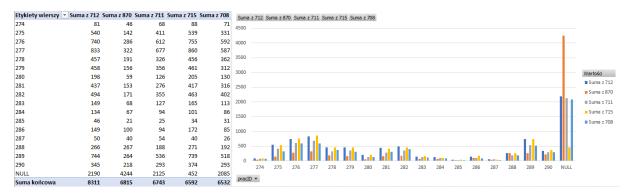
1)



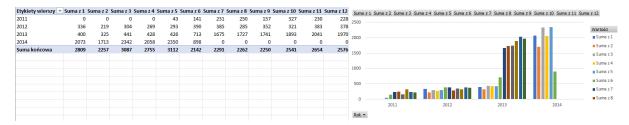
1a)

Etykiety wierszy	Suma z 2011	Suma z 2012	Suma z 2013	Suma z 2014	Suma z 2011 Suma z 2012 Suma z 2013 Suma z 2014	
274	30	1061	1366	638		
275	1394	8456	10391	2817	33000	
276	1289	9349	12880	3711		
277	2053	9396	11975	3627	30000	
278	746	3897	5215	1686		
279	1681	5780	6958	2012	25000	-
280	709	2705	2823	1123		Wartości
281	1293	5114	6940	2050	20000 —	■ Suma z 2011
282	1896	3944	6349	3031		■ Suma z 2012
283	596	2662	3692	1222	15000	■ Suma z 2013
284	0	1171	3185	1294		
285	0	0	752	73	10000	Suma z 2014
286	0	0	2470	1653		
287	0	373	1557	82	5000	
288	0	0	5035	1998		
289	0	8768	13002	4461	de la caracteria de del colo alla de alla del colo al caracteria del colo de la colo de la colo del colo del c	
290	0	3160	8239	2686	274 275 276 277 278 279 280 281 282 283 284 285 286 287 288 289 290 NUL	
NULL	1201	2743	28959	27495	·	_
Suma końcowa	12888	68579	131788	61659	PracownikID 🕶	

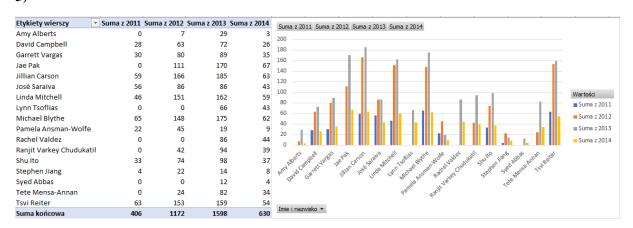
1b)

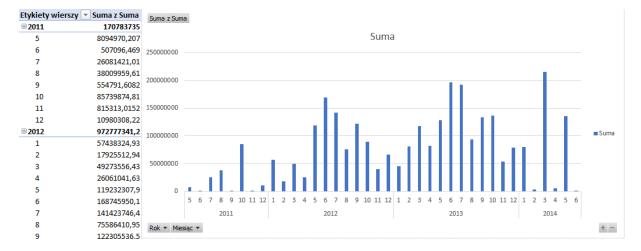


2)



3)





5)

Etykiety wierszy	▼ Suma z Suma	Suma z Suma
Luty	103403614,4	
Marzec	382618986,2	Suma
Maj	390954184,8	450000000
Czerwiec	365654294,5	40000000
Lipiec	360088403,3	350000000 30000000
Listopad	94933254,06	250000000
Grudzien	156509185,3	150000000
Kwiecien	113514051	100000000 50000000
Pazdziernik	311820065,3	0
Sierpien	207215346	Lier Hatter Mai Lerwise lidger toped Littler die the life servier street unter servier
Styczen	183378292,8	Lier Martee Mail Ligher Ligher Chutter American Service Live State Committee
Wrzesien	256880446,3	4.0
Suma końcowa	2926970124	Miesiąc ▼

Ad.3

8

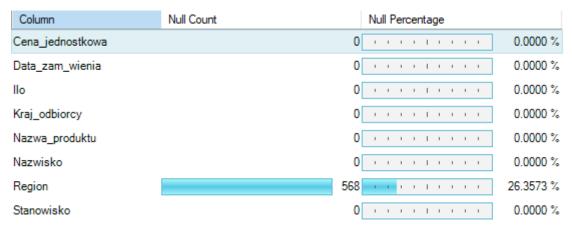
Zrzuty ekranu oraz wnioski z wyników dotyczących pliku dane 1.txt:

Column	Minimum Length	Maximum Length	Ignore Leading Spaces	IgnoreTrailing Spaces		
Cena_jednostkowa	7	9		✓		
llo	1	3		✓		
Kraj_odbiorcy	3	15		✓		
Nazwa_produktu	4	32		✓		
Nazwisko	4	9		✓		
Region	2	2		✓		
Stanowisko	22	33		✓		
Length Distribution - Cena_jednostkowa						
Length	Count	Percentage				
9		46	2.1346 %			

Dane z pliku dane_1.txt odnoszą się najprawdopodobniej do jakiegoś rodzaju restauracji. Jeśli chodzi o powyższe wyniki, to najciekawsza jest różnica w długości ceny jednostkowej. Zamówienia zaczynają się od kilku do nawet kilkuset złotych.

78.9791 %

1702



Wiele zamówień nie posiada określonego regionu (prawie 30%).

Column	Minimum	Maximum	Mean	Standard Deviation
Data_zam_wienia	04.07.1996 00:00:00	06.05.1998 00:00:00		

Restauracja rozpoczęła rejestrowanie zamówień w bazie danych w roku 1996 i działała przez prawie 2 lata.

Column	Number Of Distinct Values
Cena_jednostkowa	116
Data_zam_wienia	480
llo	55
Kraj_odbiorcy	21
Nazwa_produktu	77
Nazwisko	9
Region	1
Stanowisko	4

Value	Count	Percentage	_
06.05.1998 00:00:00		32	1.4849 %
26.02.1998 00:00:00		16	0.7425 %
06.04.1998 00:00:00		14	0.6497 %
26.03.1998 00:00:00		14	0.6497 %
17.04.1998 00:00:00		14	0.6497 %
05.05.1998 00:00:00		12	0.5568 %
06.03.1998 00:00:00		12	0.5568 %
18.02.1998 00:00:00		12	0.5568 %
09.04.1998 00:00:00		11	0.5104 %

Z powyższego zrzutu ekranu możemy uzyskać najwięcej informacji – przykładowo, że dostawy odbywały się do aż 21 różnych krajów, lub że restauracja oferowała aż 77 różnych produktów. Inną ciekawą informacją jest również to, że w ostatnim zarejestrowanym dniu w bazie wystąpiło najwięcej zamówień.

Zrzuty ekranu z wyników dotyczących pliku dane_2.csv:

Key Columns	Key Strength			
London Mean Background	To your distribution of the state of the sta	97.7904 %		
London Mean Background		98 4217 %		
London Mean Roadside Nit		98.1061 %		
London Mean Roadside Oz		97 6641 %		
London Mean Roadside PM		95.1073 %		
London Mean Moduside I M		JJ. 10/J /6		
Key Violations				
London Mean Background Nitrogen Dioxide (ug m3)	Count		Percentage	
30.2		3		0.0947 %
34.193548387096776		3		0.0947 %
36.0333333333333		3		0.0947 %
36.4		3		0.0947 %
36.354838709677416		2		0.0631 %
35.80645161290323		2		0.0631 %
35.387096774193544		2		0.0631 %
34.935483870967744		2		0.0631 %
34.16666666666664		2		0.0631 %
33.9999999999999		2		0.0631 %
33.722580645161294		2		0.0631 %
33.62		2		0.0631 %

Dane z pliku dane_2.txt odnoszą się do pewnego rodzaju bazy pomiarów składu powietrza w Londynie. Widzimy, że wszystkie z pomiarów są bardzo dokładne.

Column	Minimum Length	Maximum Length	Ignore Leading Spaces	Ignore Trailing Spaces
GMT	5	5		✓
London Mean Background	0	18		✓
London Mean Background	2	18		✓
London Mean Background	0	18		\checkmark
London Mean Background	2	18		\checkmark
London Mean Background	2	18		\checkmark
London Mean Background	0	18		✓
London Mean Background	1	18		✓
London Mean Roadside Nit	0	18		✓
London Mean Roadside Nit	2	18		✓
London Mean Roadside Ox	0	18		✓
London Mean Roadside Oz	2	18		\checkmark
London Mean Roadside PM	. 2	18		✓
London Mean Roadside PM.	. 1	18		✓
London Mean Roadside Sul	. 1	21		✓
Month (text)	10	10		✓
Length Distribution - Londo	on Mean Background Nitric C	Oxide (ug m3)		
Length	Count	Percentage		
0		576	18.1818 %	
15		1	0.0316 %	
3		10	0.3157 %	
6		3	0.0947 %	
18		1160	36.6162 %	
4		64	2.0202 %	
5		80	2.5253 %	
		83	2.6199 %	
16		63		
16 2		2		

Wiele pomiarów nie było wykonywane od początku istnienia bazy. Przeważająca większość ma również wartości o zbliżonych wartościach (długość 18 znaków). Nie licząc długości 0, można przypuszczać, że pomiary o niewielkich wartościach wynikają z błędów urządzeń pomiarowych.

Column	Null Count	Null Percentage	
GMT	0	1 1 1 1 1 1 1 1 1	0.0000 %
London Mean Background	0	1 1 1 1 1 1 1 1 1	0.0000 %
London Mean Background	0		0.0000 %
London Mean Background	0	1 1 1 1 1 1 1 1 1	0.0000 %
London Mean Background	0	1 1 1 1 1 1 1 1 1	0.0000 %
London Mean Background	0	1 1 1 1 1 1 1 1 1	0.0000 %
London Mean Background	0	1 1 1 1 1 1 1 1 1	0.0000 %
London Mean Background	0	1 1 1 1 1 1 1 1 1	0.0000 %
London Mean Roadside Nit	0	1 1 1 1 1 1 1 1 1	0.0000 %
London Mean Roadside Nit	0	1 1 1 1 1 1 1 1 1	0.0000 %
London Mean Roadside Ox	0	1 1 1 1 1 1 1 1 1	0.0000 %
London Mean Roadside Oz	0	1 1 1 1 1 1 1 1 1	0.0000 %
London Mean Roadside PM	. 0	1 1 1 1 1 1 1 1 1	0.0000 %
London Mean Roadside PM	. 0	1 1 1 1 1 1 1 1 1	0.0000 %
London Mean Roadside Sul	0	1 1 1 1 1 1 1 1 1	0.0000 %
Month (text)	0	1 1 1 1 1 1 1 1 1	0.0000 %

Nie ma pól o pustych wartościach.

Column	Number Of Distinct Values	
GMT	24	
London Mean Background	2560	
London Mean Background	3098	
London Mean Background	2572	
London Mean Background	3118	
London Mean Background	2975	
London Mean Background	2897	
London Mean Background	2573	
London Mean Roadside Nit	2577	
London Mean Roadside Nit	3108	
London Mean Roadside Ox	2581	
London Mean Roadside Oz	3094	
London Mean Roadside PM	3013	
Franciant Value Distribution	(0.1000 %) Landon Marris D	adaman and Nitria Ovida (com pa 2)
<u> </u>		ackground Nitric Oxide (ug m3)
Value	Count	Percentage
		576 18.1818

Powyższy zrzut ekranu potwierdza, że większość z wartości pomiarowych znacząco różni się od siebie (duża dokładność pomiarowa).

Wnioski:

Wnioski do zadań 1 oraz 2 (Wnioski do zadania nr 3 znajdują się pod zrzutami ekranu zamieszczonymi wyżej):

1) oraz 1a)

Dwa powyższe zrzuty ekranu prezentują to samo zestawienie, na którym warto zauważyć, że w 2013 roku następuje gwałtowny wzrost transakcji bez określonego sprzedawcy – sprzedaż internetowa.

1b)

Widzimy, że najpopularniejsze produkty były kupowane w dużych ilościach bez pomocy sprzedawców.

2)

Widać tutaj dwukrotny wzrost klientów w połowie 2013 roku. Biorąc pod uwagę poprzednie wykresy można przypuszczać, że właśnie wtedy do sklepu została wprowadzona sprzedaż internetowa. Po jej wprowadzaniu sprzedaż utrzymywała się na podobnym, wysokim poziomie.

3)

U prawie wszystkich sprzedawców możemy zaobserwować wzrost sprzedanych produktów wraz z biegiem lat. W przypadku 2014 roku trzeba brać pod uwagę, że dysponujemy danymi z jedynie połowy roku.

4)

Z roku na rok widać stopniowy wzrost łącznej kwoty zamówień. Na wykresie nie zamieszczałem liczby produktów, ponieważ jest ona nieporównywalnie mniejsza od sumy kwot zamówień.

5)

Na powyższym wykresie widać, że łączna kwota zamówień osiąga najwyższe wartości w ciepłych miesiącach, a najniższe – w najchłodniejszych.

Zadanie z zajęć:

	Dzień	S	M	L
1	1	373	206	332
2	2	418	245	370
3	3	395	206	353
4	4	394	211	314
5	5	352	216	388
6	6	303	153	299
7	7	387	194	340

Wnioski:

Widać, że klienci chętniej kupują przedmioty o mniejszych rozmiarach, lecz dzień tygodnia nie wpływa na ilość tych zakupów.